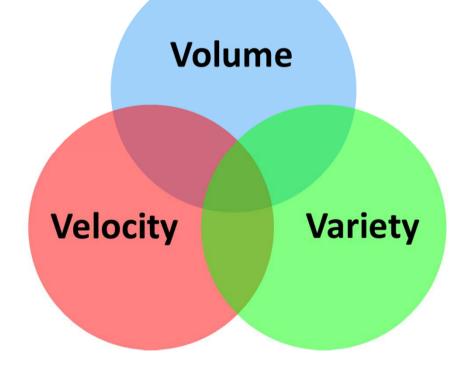
大数据系统与大规模数据分析

作业1:

大数据存储系统编程



陈世敏

中科院计算所 计算机体系结构 国家重点实验室 ©2015-2020 陈世敏

实验环境

- 虚拟机
 - □ Ubuntu 16.04 (64-bits)
 - □ Java 1.8_151
 - □ Hadoop 2.9.2
 - ☐ GraphLite 0.20.0
 - ☐ HBase 0.98
 - \Box gcc/g++ 5.4.0
- 获得
 - □安装下载docker

https://hub.docker.com/r/dingms/ucas-bdms-hw-u64-2019

课程相关

• 成绩分配

□闭卷考试: 45%

□作业1+作业2+作业3:30%

□大作业: 20%

□课堂表现:5%

作业时间安排

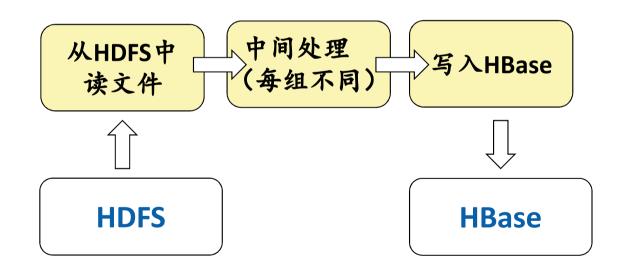
周次	内容	作业
第4周,3/11	大数据存储系统1:基础,文件系统,HDFS	作业1布置
第5周,3/18	大数据存储系统2:键值系统	
第6周,3/25	大数据存储系统3:图存储,document store	
第7周,4/1	大数据运算系统1: MapReduce, 图计算系统	作业1提交 作业2布置
第8周,4/8	大数据运算系统2:图计算系统, MR+SQL	
第9周,4/15	大数据运算系统3:内存计算系统	大作业布置
第10周,4/22	最邻近搜索和位置敏感(LHS)哈希算法	作业2提交
第11周,4/29	数据空间的维度约化	
第12周,5/6	推荐系统	作业3
第13周,5/13	流数据采样与估计、流数据过滤与分析	
第14周,5/20	教育大数据的建模与分析	
第15周,5/27	期末考试	
第16周,6/3	大作业验收报告	大作业验收

作业1安排

- 成绩: 占总成绩10%
- 时间
 - □发布: 2020/3/11(Wed)前
 - □上交: 2020/4/1(Wed), 北京时间 6:59pm (共3周)
 - □在sep课程网站>作业>作业1中提交
 - □晚交
 - 最晚: 2020/4/8(Wed), 北京时间 6:59pm, 将扣除20%成绩
 - 之后不再接收,作业1成绩为0
- 抄袭:课程总分为0!

作业内容

- 目的
 - □学习HDFS和HBase的基本编程使用
 - □巩固课堂讲授的内容
- 总体功能



分组

- 共分为6个组,每个组的作业题目有一定区别
- 分组方式如下
 - □组号=(学号最右面6位数字)%6
 - □%是求余数

• 举例

- □学号=201818013229032
- □学号最右面6位数字=229032
- □组号=229032%6=0
- □所以是第0组

中间处理



第0组	Hash join
第1组	Sort-merge join
第2组	Hash based group-by
第3组	Sort based group-by
第4组	Hash based distinct
第5组	Sort based distinct

注:

- 假设所有数据都可以放入内存
- 可以采用Java已有的库实现hash table和sorting

从HDFS中读文件

- 文件格式
 - □文本文件
 - □每一行是一个关系型记录
 - □各个列用|分开
- 例如
 - □ 1 | AMERICA | hs use ironic, even requests. s |
 - □这个是TPCH基准测试数据集中region table的一行
 - 口有3个列
 - 第0列:1
 - 第1列: AMERICA
 - 第2列: hs use ironic, even requests. S

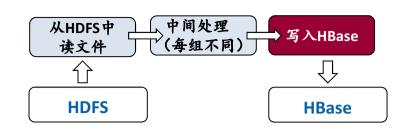
hdfs工具

```
$ hdfs dfs -help
       打印出所有命令的usage信息
-copyFromLocal [-f] [-p] [-l] <localsrc> ... <dst> :
 Identical to the -put command.
-copyToLocal [-p] [-ignoreCrc] [-crc] <src> ... <localdst> :
 Identical to the -get command.
-cat [-ignoreCrc] <src> ... :
 Fetch all files that match the file pattern <src> and display
their content on stdout.
-ls [-d] [-h] [-R] [<path> ...] :
  list contents
```

程序举例:读一个HDFS文件

```
public class HDFSTest {
 public static void main(String[] args) throws IOException, URISyntaxException{
        String file= "hdfs://localhost:9000/文件路径";
        Configuration conf = new Configuration();
        FileSystem fs = FileSystem.get(URI.create(file), conf);
        FSDataInputStream in stream = fs.open(new Path(file));
        BufferedReader in = new BufferedReader(new InputStreamReader(in stream));
        String s:
       while ((s=in.readLine())!=null) {
             System.out.println(s);
        }
        in.close();
        fs.close();
```

写入HBase



- (这部分在第5周会仔细讲解)
- •本次作业的输出写入HBase, 表名是Result, 注意大小写

- 给定了表名
 - □首先检查这个表是否存在,如果存在,那么删除
 - □创建Result表
 - □把结果写入

hbase shell

```
create 'mytable', 'mycf'
     创建表, column family
put 'mytable', 'abc', 'mycf:a', '123'
0 row(s) in 0.0580 seconds
put 'mytable', 'def', 'mycf:b', '456'
0 row(s) in 0.0060 seconds
scan 'mytable'
ROW
         COLUMN+CFLL
abc column=mycf:a, timestamp=1427731972925, value=123
def column=mycf:b, timestamp=1427731990058, value=456
2 row(s) in 0.0300 seconds
```

举例: HBase create table & Put

```
public class HBaseTest {
  public static void main(String[] args) throws MasterNotRunningException,
ZooKeeperConnectionException, IOException {
   // create table descriptor
   String tableName= "mytable";
   HTableDescriptor htd = new HTableDescriptor(TableName.valueOf(tableName));
   // create column descriptor
   HColumnDescriptor cf = new HColumnDescriptor("mvcf");
    htd.addFamily(cf);
   // configure HBase
   Configuration configuration = HBaseConfiguration.create();
   HBaseAdmin hAdmin = new HBaseAdmin(configuration);
    hAdmin.createTable(htd);
    hAdmin.close();
```

举例: HBase create table & Put

```
// put "mytable", "abc", "mycf:a", "789"

HTable table = new HTable(configuration, tableName);
Put put = new Put("abc".getBytes());
put.add("mycf".getBytes(), "a".getBytes(), "789".getBytes());
table.put(put);
table.close();
System.out.println("put successfully");
}
```

中间处理

第0组	Hash join
第1组	Sort-merge join
第2组	Hash based group-by
第3组	Sort based group-by
第4组	Hash based distinct
第5组	Sort based distinct

注:

- 假设所有数据都可以放入内存
- 可以采用Java已有的库实现hash table和sorting

第0组/第1组: Join

- 命令行:
 - □ java Hw1GrpX R=<file 1> S=<file 2> join:R2=S3 res:R4,S5
 - □蓝色是可变的参数, X=0或X=1
- 输入hdfs文件: <file 1>. <file 2>
 - □ 例如: /hw1/lineitem.tbl等
- Join key: 每个文件有一列为join key
 - □ 例如: R的第2列和S的第3列 (从第0列数起)
- 输出: 可以有1到多列
 - □ 在HBase中,建立名为Result的表, row key是join key, column family是res, column是R4和S5, value是相应的值
 - □ 例如: 一个结果join key= abc, R4= def, S5= ghi 那么在HBase的Result表中,需要有(row key=abc, res:R4=def) (row key=abc, res:S5=ghi)
- 如何实现join? 见讲义

相同join key的输出

• 例如:

- □结果包含:
 - join key= abc, R4= def, S5= ghi
 - join key= abc, R4= 123, S5= 456
 - join key= abc, R4= 789, S5= ghi
- □那么输出到Hbase:
 - (row key=abc, res:R4=def) (row key=abc, res:S5=ghi)
 - (row key=abc, res:R4.1=123) (row key=abc, res:S5.1=456)
 - (row key=abc, res:R4.2=789) (row key=abc, res:S5.2=ghi)

第2组/第3组: Group-by

- 命令行:
 - □ java Hw1GrpX R=<file> groupby:R2 'res:count,avg(R3),max(R4)'
 - □ 蓝色是可变的参数, X=2或X=3
- 输入文件: <file>
 - □ 例如: /hw1/lineitem.tbl
- Group by key: 只有一列
 - □例如: R的第2列 (从第0列数起)
- 输出:可以有1~多列,数值列
 - □ 三种形式为(a) count, (b) avg(列), (c) max(列)
 - □ 在HBase中,建立名为Result的表, row key是group by key, column family是res, column是count、avg(R3)、max(R4), value是相应的值
 - □ 例如: 一个结果groupby key= abc, count=3, avg(R3)= 10,max(R4)=20 那么在HBase的Result表中,需要有(row key=abc, res:count=3) (row key=abc, res:avg(R3)=10) (row key=abc, res:max(R4)=20)
- 注: count和max结果是准确值, avg保留小数点后2位数

举例

R0	R1	R2	R3	R4	R5
100	3	good	nice	ok	12
101	6	abc	def	better	10
102	9	abc	def	best	10
103	12	abc	def	nicest	8

java Hw1GrpX R=<file> groupby:R2 'res:count,avg(R5),max(R0)'

- 第0个结果(abc, 3, 9.33,103), 那么在HBase的Result表中有 (row key=abc, res:count=3) (row key=abc, res:avg(R5)=9.33) (row key=abc, res:max(R0)=103)
- 第1个结果(good, 1,12,100), 那么在HBase的Result表中有 (row key=good, res:count=1) (row key=good, res:avg(R5)=12) (row key=good, res:max(R0)=100)

Group by实现

Hash based

- □建立一个hash table
- □ Key= group by key
- □Value=需要统计的信息
 - Count: 目前的计数
 - Avg: 目前的sum和count
 - Max: 目前的最大值
- □把輸入都使用hash table完成统计,最后扫描输出hash table中的所有项

Sort based

- □根据group by key 排序
- □然后同一个group的都会在一起
- □统计输出

第4组/第5组: Distinct

- 命令行:
 - □ java Hw1GrpX R=<file> select:R1,gt,5.1 distinct:R2,R3,R5
 - □ 蓝色是可变的参数, X=4或X=5
- 输入文件: <file>
 - □ 例如: /hw1/lineitem.tbl等
- 选择: 只有一列, 数值列
 - □ 6种形式(a)列,gt,值,(b)列,ge,值,(c)列,eq,值,(d)列,ne,值,(e)列,le,值,(f)列,lt,值
 - □ 涵义: >gt; >= ge; == eq; != ne; le <=; lt <
 - □例如: R的第1列大于5.1 (从第0列数起)
- 输出:可以有1~多列
 - □每种组合只输出一次
 - □ 在HBase中,建立Result表,row key是序号,column family是res,column是R2,R3和R5,value是相应的值

举例

R0	R1	R2	R3	R4	R5
100	3	good	nice	ok	12
101	6	abc	def	better	10
102	9	abc	def	best	10
103	12	abc	def	nicest	8

java Hw1GrpX R=<file> select:R1,gt,5.1 distinct:R2,R3,R5

- 第0个结果(abc, def, 10), 那么在HBase的Result表中, 需要有 (row key=0, res:R2=abc) (row key=0, res:R3=def)(row key=0, res:R5=10)
- 第1个结果(abc, def, 8), 那么在HBase的Result表中, 需要有 (row key=1, res:R2=abc) (row key=1, res:R3=def)(row key=1, res:R5=8)

Distinct实现

- Selection: 每个记录依次进行比较
- Hash based
 - □建立一个hash table
 - □ Key= distinct所有key (例如: R2,R3,R5)
 - □ Value= 空
 - □把输入都放入hash table一次且仅一次,最后扫描输出 hash table中的所有项
- Sort based
 - □根据distinct key 排序
 - □然后相同的都会在一起
 - □输出

以TPCH数据为基础的例子

• Join

- □ java Hw1Grp0 R=/hw1/lineitem.tbl S=/hw1/orders.tbl join:R0=S0 res:S1,R1,R5
- □ java Hw1Grp1 R=/hw1/lineitem.tbl S=/hw1/part.tbl join:R1=S0 res:S1,S3,R5

Groupby

- ☐ java Hw1Grp2 R=/hw1/lineitem.tbl groupby:R2 'res:count,max(R5)'
- □ java Hw1Grp3 R=/hw1/orders.tbl groupby:R1 'res:count,avg(R3)'

• Distinct

- □ java Hw1Grp4 R=/hw1/part.tbl select:R7,gt,1800 distinct:R3,R4,R5
- □ java Hw1Grp5 R=/hw1/lineitem.tbl select:R4,lt,5 distinct:R13,R14,R8,R9

作业提交的格式

- 文件命名
 - □ 组号_学号_hw1.java
 - □ 例如: 0_201618013229032_hw1.java
 - □注意:上述文件名没有空格;不能上传rar或zip文件
- 程序中Java class的名字必须为
 - □ Hw1GrpX, 其中X为组号, 注意大小写
 - □例如: Hw1Grp0
- •自动检查程序会根据学号自动寻找对应的文件,重新命名为 Hw1GrpX.java、编译、执行
 - □如果名称不正确,将无法找到或不能执行,就成绩=0

错误的文件名举例

- X 0 _201018013229032_hw1.java
- X 0_201018013229032_hw1 .java
- X 0_201018013229032_hw1.java.java
- X 0_201018013229032_hw1.rar
- X 0_201018013229032_hw1.zip
- X Hw1Grp0.java
- X 0 201018013229032 hw0.java

错误的class名举例

- X public class hw1group {X public class hw1 {X public class Hw1Group2 {X public class Hw1Grp9{
- X public class MyTest {

注意事项

- •命名
 - □程序名、类名、表名、Column Family名、列名等
 - □注意大小写, 必须按照规定
- •程序注释
 - □注意程序格式,要求有Javadoc要求的注释,没有就-1
 - □只能用英文
- 仅提交一个Java文件,不能附带其他jar包
- 严禁抄袭
 - □会有自动检查程序(也会比较去年的作业)
 - □一旦发现,抄袭各方课程总成绩均为0分